Plateforme de vérification de claims scientifiques par RAG et agents IA

Domaine d'application : l'informatique

Proposition de projet — Version 1

Étudiant : Bilal Malih , Oussama mahi
Encadrante : pr : Karima MOUMANE

Résumé. Ce document présente un système qui reçoit une affirmation scientifique en informatique (par exemple : « les Transformers surpassent les LSTM sur les tâches de traduction »), recherche les articles pertinents dans un corpus local, détermine pour chaque passage s'il *soutient*, *contredit* ou *ne conclut pas*, puis produit un verdict argumenté avec des citations vérifiables et un score de confiance. Le projet repose sur une architecture RAG (*Retrieval-Augmented Generation*) pilotée par plusieurs agents spécialisés et fonctionne **entièrement en local**, sans service cloud.

1. Contexte et problématique

Contexte

Le nombre de publications en informatique, notamment en intelligence artificielle, croît très rapidement : plusieurs milliers d'articles sont déposés chaque mois sur des plateformes comme arXiv. Étudiants, ingénieurs et chercheurs doivent constamment juger de la validité d'affirmations issues d'articles, de blogs, de présentations ou de discussions techniques, sans avoir le temps de lire l'ensemble de la littérature.

Problématique

Les moteurs de recherche classiques renvoient des listes de documents, sans dire si ceux-ci appuient ou contredisent une affirmation donnée. Les grands modèles de langage (LLM), eux, répondent de façon fluide mais peuvent **halluciner** des références ou des résultats inexistants, ce qui est particulièrement problématique dans un contexte scientifique. Un RAG simple réduit ce risque sans le supprimer : il ne garantit ni que les citations sont réelles, ni que les sources sont suffisantes pour conclure.

Question de recherche : *comment concevoir un système local, fiable et vérifiable, capable d'évaluer une affirmation scientifique en informatique à partir d'un corpus d'articles, en indiquant clairement son niveau de certitude ?*

2. Objectifs

Objectif général

Concevoir et réaliser un prototype de vérification de claims scientifiques combinant recherche d'information, génération de texte et agents IA, exécutable sur un ordinateur personnel.

Objectifs spécifiques

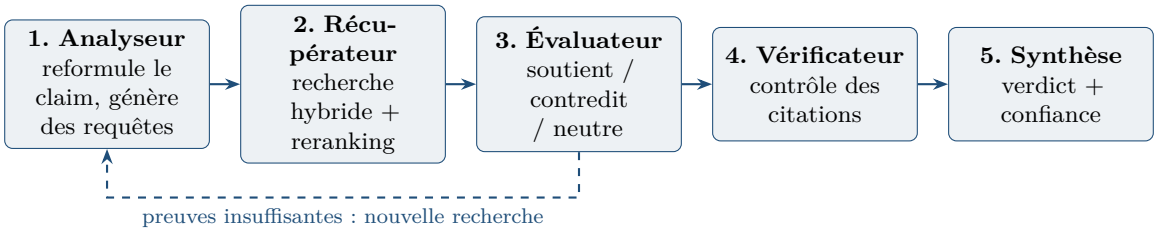
1. Constituer un corpus ciblé de 3 000 à 10 000 articles d'informatique (sections `cs.*` d'arXiv) avec leurs métadonnées (titre, auteurs, année, DOI).
2. Mettre en place une recherche hybride (lexicale BM25 + vectorielle) suivie d'un reranking.

3. Classifier la relation entre une affirmation et un passage : *soutient*, *contredit* ou *neutre*.
4. Garantir que chaque citation affichée existe textuellement dans la source.
5. Calculer un score de confiance et savoir répondre « preuves insuffisantes » lorsque c'est le cas.
6. Évaluer rigoureusement le système sur des jeux de données publics et sur un jeu de claims en informatique annoté manuellement.

3. Solution proposée

Architecture générale

Le système est organisé en un pipeline de cinq agents spécialisés, coordonnés par un orchestrateur (LangGraph ou machine à états en Python).



Lorsque les preuves sont insuffisantes, l'orchestrateur relance une recherche avec des requêtes reformulées : c'est la **boucle multi-étapes** qui distingue ce système d'un RAG classique.

Technologies envisagées (100 % local)

Composant	Outil
Modèle de langage	Ollama (Llama 3.1 8B, Qwen2.5 7B)
Embeddings	sentence-transformers (`bge-small-en-v1.5`)
Base vectorielle	ChromaDB (ou FAISS)
Recherche lexicale / reranking	`rank_bm25`, cross-encoder MiniLM
Vérification de stance	LLM + modèle NLI (DeBERTa)
Orchestration des agents	LangGraph
Backend / interface	FastAPI / Streamlit
Déploiement	Docker Compose

Mécanismes de fiabilité

— **Sorties structurées** : le LLM renvoie un JSON validé (stance, citation, confiance).

— **Vérification textuelle** : une citation n'est conservée que si elle apparaît mot pour mot dans le passage source.

— **Double validation** : accord entre le LLM et un modèle NLI pour limiter les erreurs.

— **Score de confiance composite** : nombre de sources, accord entre elles, pertinence du reranking, ancienneté des études.

4. Méthodologie d'évaluation

— **Retrieval** : Recall@k, MRR et nDCG.

— **Verdict** : exactitude (*accuracy*) et F1 par classe, sur SciFact pour valider la méthode, puis sur un jeu d'environ 100 claims d'informatique annotés manuellement.

— **Fidélité** : taux de citations valides et taux d'hallucination.

— **Étude d'ablation** : comparaison successive entre RAG simple, recherche hybride, hybride + reranking, puis système complet avec agents, afin de mesurer l'apport de chaque composant.

5. Avantages de notre solution

Vérifiabilité.
Chaque conclusion renvoie à un passage exact et à un lien (DOI ou arXiv), ce qui permet à l'utilisateur de contrôler la réponse.

Honnêteté épistémique.
Le système peut répondre « preuves insuffisantes » ou « sujet débattu » plutôt que de forcer un verdict.

Confidentialité et coût nul.
L'exécution locale évite l'envoi de données à un tiers et supprime les frais d'API ou de cloud.

Reproductibilité.
Le déploiement par Docker Compose et l'évaluation chiffrée permettent de reproduire les résultats.

Modularité.
Chaque agent est remplaçable (autre LLM, autre base vectorielle) et le corpus peut être étendu à d'autres domaines.

Valeur pédagogique et professionnelle.
Le projet couvre l'ingénierie logicielle (API, tests, conteneurisation), le RAG et les systèmes multi-agents.

6. Conclusion

notre solution propose une approche rigoureuse et réaliste pour évaluer des affirmations scientifiques en informatique, en associant RAG, agents IA et bonnes pratiques d'ingénierie logicielle. Nous sollicitons votre avis sur le périmètre du projet, le choix du corpus et la méthode d'évaluation avant de lancer la réalisation.